

JobMatch AI

AI-powered CV and Job Role Matching System

INPUT	PROCESSING	MATCHING	OUTPUT
CV PDF	PDF Extraction Cleaning TF-IDF	ML Classification Embedding Supabase pgvector Skill Matching	Predicted Category Recommended Roles Final Score

1. Tujuan Proyek

JobMatch AI adalah proyek AI untuk membantu mencocokkan CV kandidat dengan posisi pekerjaan yang tersedia. Input utama sistem adalah CV dalam format PDF. Sistem mengekstrak teks CV, memprediksi kategori pekerjaan, menghasilkan embedding, mencari role yang memiliki kemiripan semantik menggunakan Supabase PostgreSQL + pgvector, kemudian menggabungkan semantic similarity, skill matching, dan category matching menjadi ranking rekomendasi.

Fokus proyek adalah membangun pipeline end-to-end yang menggabungkan machine learning, embeddings, vector database, dan aplikasi Streamlit dalam satu sistem.

2. Komponen Utama

Komponen	Fungsi
PDF Extraction	Mengekstrak teks CV dari PDF menggunakan pypdf.
TF-IDF	Mengubah teks CV menjadi fitur numerik untuk klasifikasi.
Logistic Regression	Memprediksi kategori umum CV dari model yang telah dilatih.
Sentence Transformer	Menghasilkan embedding CV dan role dengan dimensi 384.
Supabase + pgvector	Menyimpan embedding role dan melakukan semantic similarity search.
Skill Matching	Mengukur proporsi required skills yang ditemukan pada CV.
Category Matching	Memberikan sinyal tambahan berdasarkan mapping kategori ke role.
Final Score	Menggabungkan similarity, skill match, dan category match.

3. Alur Program

1. Pengguna meng-upload CV PDF melalui Streamlit.
2. pypdf membaca setiap halaman dan mengekstrak teks CV.
3. Teks dibersihkan menggunakan fungsi `clean_resume()`.
4. Teks bersih ditransformasikan menggunakan TF-IDF.
5. Logistic Regression memprediksi kategori CV.
6. CV diubah menjadi embedding menggunakan `all-MiniLM-L6-v2`.
7. Embedding dikirim ke Supabase melalui `RPC match_company_roles()`.
8. Supabase melakukan pencarian berdasarkan cosine similarity terhadap embedding role.
9. Sistem menghitung `skill_match` berdasarkan required skills pada setiap role.
10. Sistem menghitung `category_match` berdasarkan mapping kategori prediksi ke role.
11. Final score dihitung dan role diurutkan dari skor tertinggi.
12. Streamlit menampilkan predicted category dan recommended roles.

Formula Final Score

$$\text{Final Score} = 0.5 \times \text{Similarity} + 0.3 \times \text{Skill Match} + 0.2 \times \text{Category Match}$$

Bobot tersebut merupakan baseline MVP dan belum dianggap sebagai bobot optimal karena belum dilakukan tuning khusus untuk metrik ranking recommendation.

4. Struktur Proyek

```
jobmatch-ai/  
├─ app.py  
├─ src/recommender.py  
├─ models/  
│ └─ logistic_regression.pkl  
│   └─ tfidf_vectorizer.pkl  
├─ data/  
│ └─ raw/  
│   └─ processed/  
│     └─ company_roles/  
├─ notebooks/  
└─ 01_edu_resume.ipynb
```

5. Tantangan dalam Pengerjaan

Integrasi beberapa komponen AI — Pipeline menggabungkan klasifikasi TF-IDF + Logistic Regression, embeddings, vector search, dan rule-based matching.

Perbedaan kategori dataset dan role perusahaan — Dataset resume memiliki 24 kategori, sedangkan MVP memiliki enam role perusahaan sehingga diperlukan mapping dan hasilnya tidak selalu satu-ke-satu.

Pemahaman embedding dan cosine similarity — Implementasi membutuhkan pemahaman bentuk vector, kumpulan vector, serta perbedaan Python list dan NumPy array.

Integrasi Supabase pgvector — Embedding harus memiliki dimensi yang sesuai dan pencarian dilakukan melalui RPC. Sempat ditemukan duplikasi role pada tabel sehingga data perlu dibersihkan.

Memisahkan eksperimen dan aplikasi — Model dikembangkan di notebook, lalu disimpan sebagai .pkl dan logic recommendation dipindahkan ke recommender.py.

Evaluasi recommendation — Accuracy klasifikasi dapat dihitung, tetapi kualitas ranking recommendation membutuhkan ground truth role yang sesuai dengan role perusahaan.

6. Kendala dan Solusi

Kendala	Solusi
Model dan TF-IDF hanya berada di notebook	Model Logistic Regression dan TF-IDF disimpan dengan joblib ke folder models/.
Python tidak menemukan recommender	File dibuat sebagai src/recommender.py, bukan recommender.ipynb.
Path model berbeda	Notebook menggunakan ../models/, sedangkan app.py menggunakan models/.
Streamlit sempat blank putih	Server diperiksa dengan curl; setelah server merespons dengan benar, aplikasi berhasil dirender di browser.
Duplikasi role di Supabase	Tabel company_roles dibersihkan dan enam role dimasukkan satu kali.
Metrik recommendation belum ideal	Hasil mapping awal tidak digunakan sebagai accuracy final karena ground truth role belum tersedia.


7. Hasil Pengembangan Model

Model klasifikasi menggunakan Logistic Regression dengan fitur TF-IDF. Grid search yang diuji menghasilkan $C = 2.0$ sebagai konfigurasi terbaik pada grid tersebut, dengan cross-validation accuracy sekitar 64.52%. Pada test set, model mencapai accuracy sekitar 70.24%, macro F1 sekitar 0.65, dan weighted F1 sekitar 0.69.

Pada evaluasi tambahan terhadap 20 CV dari test set, model menghasilkan 70% category accuracy (14 dari 20 CV). Angka ini merupakan evaluasi sampel, bukan pengganti evaluasi penuh pada test set.

8. Hasil Akhir Aplikasi

MVP berhasil dijalankan end-to-end menggunakan Streamlit. Pengguna dapat meng-upload CV PDF, melihat hasil ekstraksi, melihat predicted category, dan memperoleh ranking posisi berdasarkan kombinasi semantic similarity, skill matching, dan category matching.



Upload your CV

Drag and drop file here
Limit 200MB per file • PDF

Browse files

Curriculum Vitae Syarifah Kemala Putri.pdf 201.8KB

Extracted CV

CV Text

Computer Science graduate with experience in data processing, web scraping validation, and NLP research.
Skilled in Python, data analysis, and working with structured datasets. Proven ability to maintain high data quality through QC processes and consistently achieve strong KPI performance.

WORK EXPERIENCE

Website Administrator | Faculty of Engineering USU
September 2019 – September 2020
o Responsible for publishing the latest news, circulars, and activities related to the faculty.
o Responsible for organizing activity publication documents and softcopy of circulars on campus.

Predicted Category

INFORMATION-TECHNOLOGY

Recommended Roles

	role	similarity	skill_match	category_match	final_score
0	Data Scientist	0.335	0.2	1	0.4275
1	AI Engineer	0.3311	0.2	1	0.4255
2	Backend Engineer	0.2991	0.2	1	0.4095
3	Admin	0.224	0.4	0	0.232
4	HR	0.2255	0.2	0	0.1727
5	Finance	0.1888	0.2	0	0.1544

Gambar 1. Hasil akhir JobMatch AI pada Streamlit menggunakan CV PDF sebagai input.

9. Contoh Hasil pada CV Pengujian

Komponen	Hasil
Predicted Category	INFORMATION-TECHNOLOGY
Top 1	Data Scientist — final score 0.4275
Top 2	AI Engineer — final score 0.4255
Top 3	Backend Engineer — final score 0.4095
Top 4	Admin — final score 0.2320
Top 5	HR — final score 0.1727
Top 6	Finance — final score 0.1544

10. Kesimpulan

JobMatch AI berhasil dikembangkan sebagai MVP sistem matching CV dan job role berbasis AI. Proyek ini menunjukkan integrasi antara machine learning tradisional, semantic embeddings, vector database, dan aplikasi Streamlit. Sistem telah berhasil menerima CV PDF nyata dan menghasilkan kategori kandidat serta ranking enam role perusahaan. Pengembangan selanjutnya dapat difokuskan pada peningkatan kualitas recommendation, penyediaan ground truth role untuk evaluasi ranking, perbaikan skill extraction, dan penyempurnaan antarmuka pengguna.